

Rapport de Recherche : Reproduction et Adaptation Spécifique d'ESRGAN pour l'Imagerie Satellite

Saad BENNAI

Fares MOULOUDI

Ilyass SALHI

Ryad ZIOUCHE

ING3-IA-B

2025-2026

Sous la direction du Prof. Arthur SATOUF

21 avril 2026

Résumé

Ce rapport détaille la reproduction du modèle Enhanced Super-Resolution Generative Adversarial Networks (ESRGAN) et son adaptation à l'imagerie satellite. Nous explorons le phénomène d'hallucination inhérent aux architectures GAN et démontrons comment un entraînement sur un domaine spécifique permet de restaurer la fidélité structurelle là où les modèles généralistes échouent.

Table des matières

1	Introduction	3
2	Objectifs et Méthodologie	3
3	Stratégie de Données : Le Dataset UCMerced	3
3.1	Justification du choix pour le Fine-Tuning	3
3.2	Limites Industrielles	3
4	Implémentation Technique	4
4.1	Phase de Dégradation	4
4.2	Paramètres d'Entraînement	4
5	Analyse Qualitative : Le Phénomène d'Hallucination	4
5.1	Le modèle Fine-Tuné (Entraîné) : Correction Structurale	4
6	Résultats Quantitatifs et Comparaisons	5
6.1	Étape 1 : Performance du Modèle Baseline (Non Entraîné)	5
6.2	Étape 2 : Performance du Modèle Fine-Tuné (Entraîné)	5
7	Discussion et Interprétation	6
8	Conclusion	6

1 Introduction

La Super-Résolution d'Image Unique (SISR) vise à reconstruire une image haute résolution (HR) à partir d'une version basse résolution (LR). L'architecture ESRGAN, introduite par Wang et al. (2018), a marqué un tournant en remplaçant les blocs résiduels classiques par des blocs *Residual-in-Residual Dense Blocks* (RRDB) et en utilisant une fonction de perte perceptuelle plus fine.

L'enjeu de ce projet est de vérifier la capacité d'adaptation de ce modèle à des données pour lesquelles il n'a pas été conçu : l'imagerie satellite. Contrairement aux images de paysages naturels ou de visages, l'imagerie satellite exige une précision géométrique stricte.

2 Objectifs et Méthodologie

Conformément à notre proposition de recherche [1], nos objectifs sont :

- Reproduire le pipeline ESRGAN original (Baseline).
- Identifier et quantifier les « hallucinations » (détails inventés mais erronés) générées par le modèle Baseline sur les structures urbaines.
- Fine-tuner le modèle sur un dataset spécialisé pour améliorer les métriques de ressemblance avec la réalité (PSNR et SSIM).

3 Stratégie de Données : Le Dataset UCMerced

Pour l'adaptation du modèle, nous avons sélectionné le dataset UCMerced (2100 images).

3.1 Justification du choix pour le Fine-Tuning

L'utilisation de cet échantillon restreint mais ciblé est justifiée par plusieurs points clés :

1. **Transfer Learning** : Nous n'entraînons pas l'IA de zéro. Le modèle ESRGAN Baseline sait déjà gérer les contrastes et les contours. 2100 images suffisent pour modifier son « vocabulaire visuel » afin qu'il apprenne à dessiner des structures spécifiques (toits, pistes, zones industrielles).
2. **Exploitation par Patches** : En Super-Résolution, les images sont découpées en patches (ex : 128x128). Une image de 256x256 fournit plusieurs patches d'entraînement. Avec la *Data Augmentation* (rotations, miroirs), le nombre d'exemples d'entraînement réels s'élève à plusieurs dizaines de milliers.
3. **Contraintes Matérielles (Google Colab)** : Un dataset massif comme DOTA (50 Go) saturerait la mémoire vive (RAM) et l'espace disque des sessions standard. Ce format (300 Mo) assure une convergence stable et rapide sur GPU.

3.2 Limites Industrielles

Il est important de noter que pour un usage commercial (Airbus, Google Earth), ce volume serait insuffisant. Un modèle industriel nécessite des millions d'exemples pour

couvrir toutes les conditions climatiques et géographiques. Cependant, pour cette preuve de concept académique, cet échantillon est statistiquement pertinent.

4 Implémentation Technique

Le pipeline se divise en deux phases : la dégradation contrôlée et la reconstruction.

4.1 Phase de Dégradation

Pour évaluer le modèle, nous créons artificiellement des images basse résolution (LR) en divisant la taille des images originales (HR) par 4 via une interpolation bicubique. Une correction géométrique (Modulo 4) est appliquée pour garantir que les dimensions HR et LR sont parfaitement comparables lors du calcul des métriques.

4.2 Paramètres d'Entraînement

Le fine-tuning a été réalisé sur 5000 itérations (soit environ 19 epochs) avec un optimiseur Adam et un taux d'apprentissage de 1×10^{-4} .

5 Analyse Qualitative : Le Phénomène d'Hallucination

Avant d'analyser les chiffres, l'inspection visuelle montre que le modèle Baseline « invente » des détails organiques (ressemblant à des feuillages ou des briques) sur des routes ou des toits lisses.



FIGURE 1 – Visualisation des hallucinations du modèle Baseline sur le domaine satellite.

5.1 Le modèle Fine-Tuné (Entraîné) : Correction Structurale

Après entraînement sur le domaine spécifique, l'IA respecte davantage les formes géométriques et réduit les inventions injustifiées.




FIGURE 2 – Amélioration après Fine-Tuning : meilleure fidélité aux structures satellitaires.

6 Résultats Quantitatifs et Comparaisons

Nous utilisons deux métriques standard : le PSNR (Peak Signal-to-Noise Ratio) pour le bruit et le SSIM (Structural Similarity Index Measure) pour la fidélité des formes.

6.1 Étape 1 : Performance du Modèle Baseline (Non Entraîné)

Ici, nous comparons le modèle original avec un zoom classique (Bicubique). On observe que l'IA dégrade parfois le score par rapport à un zoom simple à cause de ses inventions erronées.

TABLE 1 – Métriques de la Baseline vs Zoom Classique

Image	PSNR (dB) ↑		SSIM ↑	
	Zoom Classique	Baseline ESRGAN	Zoom Classique	Baseline ESRGAN
Satellite 1	19.05	12.51	0.7108	0.2914
Satellite 2	22.07	14.87	0.7998	0.3470
Satellite 3	19.50	13.16	0.6646	0.2685
Satellite 4	23.96	15.13	0.8478	0.3996
Moyenne	21.14	13.92	0.7557	0.3266

6.2 Étape 2 : Performance du Modèle Fine-Tuné (Entraîné)

Après entraînement sur les données satellites, nous constatons une remontée significative des scores.

TABLE 2 – Métriques du Modèle Fine-Tuné vs Baseline

Image	PSNR (dB) ↑		SSIM ↑			
	Baseline	ESRGAN	Fine-Tuned	Baseline	ESRGAN	Fine-Tuned
Satellite 1		12.51	15.30		0.2914	0.4162
Satellite 2		14.87	17.14		0.3470	0.4970
Satellite 3		13.16	15.57		0.2685	0.3844
Satellite 4		15.13	14.76		0.3996	0.4137
Moyenne		13.92	15.69		0.3266	0.4278

7 Discussion et Interprétation

L’analyse des tableaux démontre deux phénomènes majeurs identifiés dans notre proposition de recherche [1] :

1. **Le Gain du Fine-Tuning** : Le SSIM moyen est passé de 0.32 à 0.42, soit une progression de plus de 30%. Cela prouve que le modèle a commencé à apprendre les structures géométriques propres au domaine satellite, réduisant ainsi les hallucinations organiques.
2. **Le Compromis Perception-Distorsion** : Malgré l’amélioration, les scores restent inférieurs au zoom bicubique (0.75). Cela est dû au fait que ESRGAN privilégie la netteté visuelle (Perception) plutôt que l’exactitude mathématique pixel-par-pixel (Distorsion). Pour l’œil humain, l’image IA semble bien meilleure, même si mathématiquement elle diffère légèrement de l’originale.

8 Conclusion

Ce projet a permis de valider l’architecture ESRGAN tout en soulignant l’importance critique de la spécialisation du domaine de données. Bien que l’architecture soit puissante, sa « créativité » (hallucination) doit être bridée par un entraînement spécifique pour des applications de précision comme la cartographie satellite. L’amélioration de 30% du SSIM valide notre démarche et ouvre la voie à des entraînements plus longs pour atteindre des standards industriels.

Références

- [1] Research Proposal : *Reproducing and Adapting Enhanced Super-Resolution Generative Adversarial Networks (ESRGAN)*, 2026.
- [2] Wang, X., Yu, K., et al. (2018). *ESRGAN : Enhanced Super-Resolution Generative Adversarial Networks*. arXiv :1809.00219.